



UNIVERSITÀ DEGLI STUDI ROMA TRE

Dipartimento di Ingegneria Civile, Informatica e delle
Tecnologie Aeronautiche

Corso di Laurea Triennale in Ingegneria Informatica

Tesi di Laurea Triennale

ELETTROENCEFALOGRAFIA APPLICATA ALLE BRAIN-COMPUTER INTERFACE

Laureando

Alessio Paparcurio

Matricola 634690

Relatore

Prof. Fabio Gasparetti

Anno Accademico 2025/2026

Abstract

Indice

Abstract	ii
Indice	iii
Elenco delle figure	v
Elenco delle tabelle	vi
1 Introduzione	1
2 Principali tecnologie e paradigmi moderni	5
2.1 Le tecnologie per il tracciamento del segnale elettroencefalografico	5
2.2 Paradigmi per l'acquisizione dati	6
2.3 Algoritmi per l'estrazione e la selezione di feature	8
3 Dataset	12
3.1 Il dataset EEG Motor Movement/Imagery	12
3.2 Il protocollo sperimentale	13
3.3 Organizzazione dei dati	14
3.4 Limiti del dataset	15

4	Classificatore e predittore di illiteracy	17
4.1	Struttura del classificatore	17
4.2	Lettura dei dati e pre-processing	18
4.3	Segmentazione dei dati	20
4.4	Estrazione delle feature	22
4.5	Classificazione e validazione	26
4.6	Il predittore di illiteracy	28
5	Risultati sperimentali	31
5.1	Le classificazioni binarie	32
5.1.1	Il ruolo dei campioni scartati	33
5.1.2	Il confronto con e senza scarto	34
5.2	La coerenza della prestazione fra compiti	35
5.3	Il sistema completo a cascata	36
5.4	Le prestazioni migliori	38
5.5	Il predittore di illiteracy	39
5.5.1	L'impiego come regola di selezione	41
5.6	Sintesi	42
6	Conclusione e sviluppi futuri	43
6.1	Setup sperimentale	43
	Bibliografia	46

Elenco delle figure

- 5.1 Distribuzione della prestazione individuale nei tre compiti. La linea punteggiata indica il livello del caso, quella tratteggiata la soglia di significatività. 32
- 5.2 Prestazione dei medesimi soggetti in coppie di compiti differenti. Ogni punto rappresenta un soggetto. 35
- 5.3 A sinistra le prestazioni dei due stadi valutati separatamente, il loro prodotto e la catena effettiva; in rosso il livello del caso di ciascuno. A destra la matrice di confusione della catena, normalizzata per riga. 37
- 5.4 Prominenza del ritmo sensomotorio a riposo contro prestazione conseguita: a sinistra per il compito sinistra/destra, a destra per il compito pugni/piedi. Ogni punto è un soggetto. 40

Elenco delle tabelle

5.1	Prestazione media sui 109 soggetti nelle tre classificazioni binarie. L'accuratezza è la balanced accuracy calcolata sulle sole finestre accettate, e va letta congiuntamente alla percentuale di finestre scartate riportata nella penultima colonna.	32
5.2	Classificazione pugni/piedi con e senza scarto delle finestre, per quartili di soggetti ordinati secondo l'accuratezza senza scarto.	34
5.3	Prestazione del soggetto migliore e media degli undici soggetti migliori per ciascun compito. Per la cascata il livello del caso è il venti per cento.	38
5.4	Correlazione di Spearman fra la prominenza del ritmo sensomotorio a riposo e la prestazione conseguita, su 109 soggetti. Tutti i valori riportati hanno significatività inferiore a 10^{-3}	40
5.5	Accuratezza media nel compito sinistra/destra al variare della quota di soggetti esclusi in base al predittore.	41

Capitolo 1

Introduzione

Misurare, analizzare e classificare segnali fisiologici provenienti dal corpo umano rappresenta uno dei campi di ricerca più affascinanti e all'avanguardia del panorama scientifico. I progressi nella strumentazione, nelle tecnologie, nei paradigmi e negli algoritmi degli ultimi decenni hanno portato notevoli miglioramenti nell'assistenza all'uomo e alla sua cura.

Nel campo della misurazione dell'attività cerebrale, ricerche sempre più avanzate forniscono descrizioni dettagliate sul funzionamento delle reti cerebrali, sulle relazioni tra funzioni e specifiche aree o determinati ritmi motori e sul comportamento dinamico durante i processi cognitivi. Da queste informazioni derivano gli strumenti fondamentali per la caratterizzazione di malattie e alterazioni neurologiche, quali epilessia, demenze, Parkinson, Alzheimer. Sulla base di queste informazioni è oggi inoltre possibile pianificare interventi medici al cervello.

In questo contesto è rilevante il campo della classificazione dell'intenzione cerebrale associata a determinati paradigmi, quali l'immaginazione motoria e la stimolazione esterna. Nata a partire dal 1971 [1] e da allora in costante sviluppo, la classificazione dei segnali cerebrali ha permesso la nascita di tecnologie di nuova frontiera quali, prime fra tutte,

le Brain-Computer Interface (BCI). Questi dispositivi utilizzano le informazioni estratte dall'attività cerebrale per mettere in comunicazione il cervello di un soggetto con un dispositivo esterno in modo tale da controllarlo assecondando l'intenzione umana.

Si distinguono due direzioni progettuali che mirano ad obiettivi diversi: sistemi BCI a ciclo aperto oppure a ciclo chiuso. I sistemi a ciclo aperto o unidirezionali pongono come obiettivo la realizzazione di una strumentazione a sostegno del soggetto. I sistemi a ciclo chiuso prevedono invece un meccanismo di feedback essenziale per le operazioni di neuroriabilitazione.

La prima direzione si appoggia su una serie altamente variegata di strumenti e algoritmi che ne rendono difficile la sintesi e che saranno difatti approfonditi nel prossimo capitolo. Seguendo la tendenza di maggior rilievo, il lavoro ambisce a contribuire nell'ambito dei sistemi BCI sostenuti da misurazioni elettroencefalografiche (EEG) di superficie. L'EEG è allo stato attuale il metodo più popolare: presenta costi relativamente ridotti, elevata portabilità e misura direttamente l'attività neuronale.

Il lavoro ha portato allo sviluppo di due strumenti che sfruttassero tutti i dati forniti dal dataset di riferimento, dettagliatamente descritto nel capitolo 3. In particolare sono stati sviluppati:

- Un classificatore asincrono basato su geometria riemanniana e valutato sulla segmentazione dei dati in finestre scorrevoli (sliding windows). A sostegno del classificatore è stato implementato un algoritmo di selezione delle finestre atto ad aumentare l'accuratezza al costo di una minore percentuale di classificazioni accettate.
- Un predittore di performance che individua una correlazione tra la prominenza dei ritmi μ a riposo e l'accuratezza dello stesso soggetto.

Per quanto concerne il classificatore, le sue caratteristiche si discostano dagli approcci utilizzati da lavori simili: la maggioranza degli articoli che impiegano lo stesso dataset adottano il meccanismo di epoching e restituiscono, dunque, stime generose. Il primo obiettivo è stato quello di valutare quanto un algoritmo di classificazione sia in grado di apprendere nelle condizioni meno favorevoli che un sistema BCI reale possa incontrare. In particolare, oltre alle limitazioni imposte dal dataset, si aggiungono alcune scelte di valutazione deliberatamente severe:

- **una quantità ridotta di dati:** nelle classificazioni binarie l'addestramento è effettuato su due sole run, ossia circa quattro minuti di registrazione;
- **una validazione Leave-One-Run-Out:** il modello viene sempre valutato su un'intera run mai vista in fase di addestramento, così che finestre sovrapposte appartenenti allo stesso trial non possano comparire contemporaneamente nell'insieme di training e in quello di test;
- **una segmentazione asincrona in finestre scorrevoli:** il classificatore decide su finestre di due secondi, con passo di mezzo secondo, lungo l'intera registrazione, come avverrebbe in un utilizzo reale del dispositivo.

Le accuratezze riportate in questa tesi non sono pertanto direttamente confrontabili con quelle della letteratura e vanno lette come una stima conservativa di quanto sia possibile ottenere. Se l'algoritmo riesce ad estrarre informazione utile in queste condizioni, è ragionevole attendersi che la prestazione possa soltanto migliorare con soggetti addestrati, sessioni multiple e un meccanismo di feedback.

I risultati ottenuti riflettono direttamente la capacità di ogni soggetto di emettere informazione utile ai fini della classificazione. Le accuratezze misurate esprimono quante fine-

stre, in percentuale rispetto al totale, sono state classificate correttamente nei vari compiti di immaginazione motoria: pugno sinistro contro pugno destro, piedi contro pugni, riposo contro attivazione. Infine, essendo il sistema rivolto ad applicazioni real time, le singole classificazioni sono state concatenate in un sistema a cascata che esegue la classificazione tra tutti i possibili stati.

Il secondo obiettivo, strettamente legato al primo, è comprendere quanto della variabilità osservata dipenda dall'algoritmo e quanto dal soggetto. A questo scopo le prestazioni sono state analizzate soggetto per soggetto, sia confrontando compiti di natura diversa sia isolando i soggetti migliori, e sono state messe in relazione con il predittore di performance, che a partire da un solo minuto di registrazione a riposo stima in anticipo la capacità del soggetto di controllare il sistema basato sull'immaginazione motoria.

La tesi è organizzata come segue. Il capitolo 2 presenta le principali tecnologie per la misurazione dell'attività cerebrale, i paradigmi di acquisizione dei dati e gli algoritmi di estrazione delle feature impiegati nei sistemi BCI. Il capitolo 3 descrive il dataset utilizzato, il protocollo sperimentale con cui è stato raccolto, l'organizzazione delle registrazioni in run, trial e finestre e i limiti di cui tenere conto nell'interpretazione dei risultati. Il capitolo 4 illustra l'architettura sviluppata: il pre-processing, la segmentazione in finestre scorrevoli, l'estrazione delle feature riemanniane, la classificazione con la relativa validazione e il predittore di illiteracy. Il capitolo 5 riporta i risultati sperimentali delle classificazioni binarie, del sistema completo a cascata e del predittore, con particolare attenzione alla variabilità fra soggetti. Il capitolo 6, infine, discute i risultati ottenuti alla luce degli obiettivi posti, ne trae le conclusioni e individua i limiti del lavoro e i possibili sviluppi futuri.

Capitolo 2

Principali tecnologie e paradigmi moderni

La varietà di dispositivi e paradigmi disponibili per la raccolta di informazioni cerebrali e la rapidità nello sviluppo di nuovi algoritmi sempre più complessi rendono essenziale il confronto continuo con la letteratura attuale. Consapevole di ciò, la comunità scientifica rinnova costantemente le review [2, 3, 4] e le mette a disposizione della collettività così da sviluppare una ricca rete internazionale. In particolare, sono tre gli aspetti presi principalmente in considerazione: l'hardware, il software e i paradigmi per l'estrazione dei dati.

2.1 Le tecnologie per il tracciamento del segnale elettroencefalografico

Seppur all'interno della ricerca venga preso in considerazione esclusivamente l'elettroencefalografo, è importante soffermarsi su tutte le strumentazioni disponibili ad oggi. In base

al grado di invasività è possibile distinguere due macrocategorie: interfacce neurali invasive e non invasive [5]. I dispositivi invasivi impiegano microelettrodi intracorticali impiantati direttamente nell'encefalo. Rientrano in questa categoria l'EEG di profondità e l'elettrocorticografia (ECoG). Le tecnologie non invasive si limitano invece a misurare l'attività cerebrale dalla superficie dello scalpo o comunque in maniera indiretta. Sono tecnologie non invasive l'elettroencefalografia (EEG), la magnetoencefalografia (MEG), la risonanza magnetica funzionale e la spettroscopia funzionale nel vicino infrarosso. I dispositivi invasivi forniscono un'elevata risoluzione spaziale e temporale, un'eccellente qualità del segnale e la possibilità di effettuare misurazioni altamente localizzate. In compenso, l'invasività della procedura chirurgica necessaria per l'impianto riduce drasticamente la portabilità della metodologia e aumenta notevolmente i costi associati. Il rischio di infezioni o di danni tissutali, nonché il rigetto e il decadimento dei microelettrodi impiantati complicano ulteriormente il quadro [6]. I dispositivi non invasivi presentano caratteristiche opposte: ridotta risoluzione spaziale, elevata sensibilità ai disturbi, alle interferenze ambientali e agli artefatti muscolari e oculari, bassa localizzazione. Sono caratterizzati, però, da costi relativamente ridotti e facilità d'uso. Nel contesto delle BCI, l'EEG assume un ruolo centrale grazie alla sua elevata portabilità e alla misura che effettua, unica a restituire dati diretti dell'attività neuronale.

2.2 Paradigmi per l'acquisizione dati

Nei sistemi BCI è necessario sottoporre i soggetti a determinati stimoli e richieste per ricavare informazioni utili e riproducibili. L'insieme di questi attributi definisce un paradigma di acquisizione dei dati. Negli anni sono state proposte differenti tipologie di paradigmi con lo scopo di comprendere il potenziale di differenti canali comunicativi. Ad oggi sono due le

CAPITOLO 2. PRINCIPALI TECNOLOGIE E PARADIGMI MODERNI 7

metodologie principali: i paradigmi di immaginazione motoria (Motor Imagery Paradigms, MIP) e i paradigmi basati su stimolazioni esterne (External Stimulation Paradigms, ESP) [3]. Gli MIP sono basati sull'immaginazione motoria di movimenti di grandi parti del corpo: durante una sessione con tale paradigma, al soggetto viene richiesto di immaginare un movimento cinestetico senza eseguire realmente tale gesto. Lo scopo è quello di scatenare le event-related desynchronizations (ERD), una diminuzione temporanea della potenza di specifiche bande di frequenza, prominente nei ritmi μ (8-12 Hz) e β (18-26 Hz), rispetto a un livello di riferimento, generalmente associato allo stato di rilassamento durante il quale si verifica l'evento opposto, le event-related synchronizations (ERS). L'obiettivo di tale sistema è quello di tradurre l'intenzione cerebrale di soggetti con limitate capacità motorie in comandi utili. In base alla tipologia di classificazione si distinguono due classi: i sensorimotor rhythms paradigms sono associati ad una classificazione discreta, all'interno della quale ogni intenzione cerebrale è tradotta in uno specifico comando all'interno di un ristretto insieme di possibilità; gli imagined body kinematic paradigms fanno invece uso di un controllo ad elevata dimensionalità con lo scopo di decodificare i parametri cinematici continui del movimento immaginato. Entrambi gli approcci sono caratterizzati da una lenta curva di apprendimento ed una ridotta adattabilità, nonché da un'elevata variabilità fra soggetti: una parte non trascurabile degli utenti non riesce infatti a controllare il sistema, fenomeno noto come BCI illiteracy. Gli ESP sfruttano invece variazioni dell'attività cerebrale a seguito di stimolazioni esterne di tipo visivo, uditivo o somatosensoriale. Tali variazioni sono note nella letteratura scientifica come Event-Related Potentials (ERP): somministrando lo stesso stimolo un elevato numero di volte ed eseguendo operazioni di averaging è possibile visualizzare una risposta cerebrale fisiologica. Non è possibile, in generale, visualizzare la reazione ad un singolo stimolo: per questo motivo i tempi di la-

tenza di questa famiglia di paradigmi rappresentano uno degli ostacoli principali. Anche in questo caso sono comunemente distinte due classi di paradigmi, il Visual P300 paradigm e lo Steady State Visual Evoked Potentials Paradigms (SSVEP) [7]. Entrambi gli approcci si basano sulla somministrazione di uno stimolo visivo intermittente, presentato in determinati istanti di tempo oppure ad una precisa frequenza. Al soggetto viene richiesto di visualizzare il quadrante luminoso associato al comando che è intenzionato a mettere in atto e l'algoritmo di riconoscimento esegue la classificazione di tale intenzione. Rispetto al precedente paradigma, l'ESP è semplice e immediato e richiede una calibrazione rapida di pochi minuti. Lo sforzo visivo e il grado di attenzione richiesto sono però limiti significativi. Quando l'intenzione del soggetto non corrisponde all'azione eseguita dal sistema BCI si manifesta un Error-Related Potential (ErrP) nella corteccia mediale-frontale, con una latenza di 200-700 ms. La ricerca moderna sta implementando questa metodologia principalmente in sistemi autonomi nei quali viene richiesto ai soggetti di supervisionare e correggere eventuali comportamenti errati. Individuare una correlazione tra l'ampiezza del segnale e il corrispettivo errore e riuscire ad utilizzare queste informazioni per ottenere una correzione real-time sono gli aspetti principalmente indagati. Infine, è possibile utilizzare una qualsiasi combinazione di dispositivi hardware e paradigmi e sviluppare nuove forme di hybrid paradigms. L'impiego può essere in serie, con l'output di un paradigma utilizzato in input per il successivo paradigma, oppure in parallelo. Ne sono un esempio gli studi combinati di SSVEP e P300 per l'estrazione contemporanea delle informazioni di velocità.

2.3 Algoritmi per l'estrazione e la selezione di feature

Come avviene anche in altre tipologie di pipeline per il machine learning, anche nel caso dei sistemi BCI i metodi di classificazione non si limitano all'uso di un unico classifica-

tore ma necessitano anzi di algoritmi per l'estrazione e la selezione di feature necessari per una rappresentazione compatta e discriminativa dei segnali EEG [8]. A seguito delle procedure di pre-processing, che applicano filtri sia temporali che spaziali, è possibile sintetizzare l'informazione contenuta nel segnale elaborato attraverso degli algoritmi di feature extraction. Il risultato di questa procedura è un vettore di feature di dimensionalità d . È possibile rappresentare i segnali EEG in differenti modi, ognuno dei quali trasporta con sé una frazione dell'intera informazione. Le feature più semplici e significative si osservano nel dominio del tempo: media, varianza, deviazione standard, energia del segnale, sono parametri immediati e semplici, utili per valutare la qualità del segnale; contengono però un'esigua quantità di informazioni nel contesto BCI e sono poco robuste al rumore. Nel dominio delle frequenze è contenuta l'informazione fondamentale della densità spettrale, dalla quale è possibile ricavare la potenza per ogni specifica banda EEG; il motore di questa informazione è la ormai nota correlazione tra specifiche bande e determinate attività. Per non perdere l'informazione temporale è possibile, inoltre, applicare strumenti quali la trasformata di Wavelet o la Short-Time Fourier Transform (STFT) così da estrarre una rappresentazione tempo-frequenziale, altamente indicata per l'EEG per via della sua non stazionarietà, seppur costosa computazionalmente. Infine, molte informazioni sono disponibili all'interno del dominio dello spazio dove si ricercano combinazioni tra canali attraverso il rintracciamento di canali correlati o l'impiego di algoritmi altamente specializzati quali il Common Spatial Patterns (CSP). Studi moderni suggeriscono un nuovo paradigma secondo il quale è possibile ottimizzare l'informazione attraverso rappresentazioni matriciali o tensoriali, piuttosto che vettoriali [2]. Frequentemente questo genere di approccio fornisce feature che sono combinazioni lineari di informazioni contenute in diversi domini e dunque di difficile interpretazione fisica; nonostante ciò, i contributi per il settore delle BCI

sono notevoli e dunque non trascurabili. Prima di eseguire la classificazione è possibile aggiungere un ulteriore step, la feature selection: si seleziona un sottoinsieme delle feature precedentemente calcolate con lo scopo di ottenere una rappresentazione più compatta. Le ragioni di questa operazione sono molteplici: ridurre la dimensionalità del problema e, con essa, il rischio di overfitting, particolarmente elevato quando il numero di trial disponibili è ridotto rispetto a quello delle feature; eliminare le feature ridondanti o poco informative, che aggiungono soltanto rumore; ridurre il costo computazionale, aspetto rilevante per i sistemi in tempo reale; infine, facilitare l'interpretazione dei risultati, individuando ad esempio i canali o le bande di frequenza più discriminanti [8]. Ultimo elemento della pipeline è il classificatore, che associa a ciascun vettore di feature la classe corrispondente. Negli ultimi anni le reti neurali e, più in generale, gli algoritmi di deep learning hanno conosciuto una rapida diffusione anche nel settore delle BCI [4]: le reti convoluzionali e ricorrenti sono in grado di apprendere direttamente dal segnale poco elaborato, integrando in un unico modello le fasi di estrazione delle feature e di classificazione. A fronte di questi vantaggi, tali modelli richiedono grandi quantità di dati per l'addestramento e un elevato costo computazionale, e restituiscono risultati di difficile interpretazione. Per questo motivo i classificatori più classici mantengono ancora oggi un ruolo centrale [8, 2]. L'analisi discriminante lineare (LDA) individua l'iperpiano che meglio separa le classi, assumendo per ciascuna una distribuzione gaussiana con matrice di covarianza comune: è semplice, rapida e poco soggetta a overfitting, e la sua variante con contrazione (shrinkage) risulta particolarmente adatta quando i campioni disponibili sono pochi rispetto al numero di feature. Le macchine a vettori di supporto (SVM) ricercano invece l'iperpiano che massimizza il margine fra le classi e, attraverso l'impiego di funzioni kernel, possono modellare anche confini non lineari. Nei contesti caratterizzati da pochi dati per soggetto, come quello di

CAPITOLO 2. PRINCIPALI TECNOLOGIE E PARADIGMI MODERNI¹¹

questa tesi, entrambi offrono prestazioni spesso confrontabili con quelle delle reti neurali a un costo computazionale nettamente inferiore.

Capitolo 3

Dataset

Con l'impiego di dispositivi hardware sempre più rapidi e semplici da installare è aumentata considerevolmente la quantità di dati EEG disponibile in rete. Questo ha permesso di lavorare su dataset contenenti dati fortemente eterogenei provenienti da soggetti, sessioni o strumentazioni differenti. Non è un caso, infatti, che algoritmi di deep learning, che richiedono grandi quantità di dati, o di transfer learning, che migliorano la performance cross-subject, siano in costante miglioramento. In questo capitolo vengono descritti il dataset impiegato nel lavoro di tesi, il protocollo con cui è stato raccolto, l'organizzazione delle registrazioni e i limiti di cui è necessario tenere conto nell'interpretazione dei risultati.

3.1 Il dataset EEG Motor Movement/Imagery

Le analisi presentate in questa tesi sono state condotte sull'EEG Motor Movement/Imagery Dataset, raccolto dal gruppo di sviluppo del sistema BCI2000 e distribuito liberamente attraverso l'archivio PhysioNet. Si tratta di una delle raccolte più ampie disponibili per il paradigma di immaginazione motoria: comprende oltre millecinquecento registrazioni

provenienti da 109 volontari, acquisite con 64 elettrodi disposti secondo il sistema internazionale 10-10 e campionate a 160 Hz. Il dataset risponde ad esigenze specifiche e ha permesso di strutturare il progetto sulle due linee caratterizzanti costituite da classificatore e predittore. La prima caratteristica di rilievo è la numerosità dei soggetti: l'elevato numero di registrazioni eterogenee fornisce informazioni utili per la misurazione delle variazioni tra soggetti e run distinte. La stessa proprietà favorisce risultati statisticamente più significativi nella valutazione del predittore. La seconda caratteristica riguarda la varietà di compiti richiesti ad ogni soggetto: la presenza, per ciascuna misurazione, di run di immaginazione motoria e di esecuzione motoria rafforza la validità degli algoritmi e permette confronti semplici e diretti. Oltre a queste richieste, sono presenti run a riposo e sono proprio queste ad aver permesso lo sviluppo di un predittore. Queste proprietà riflettono i diffusi utilizzi del dataset in ambito scientifico, dove viene regolarmente impiegato come benchmark per ottimizzare e validare i propri algoritmi.

3.2 Il protocollo sperimentale

Ogni soggetto viene sottoposto a quattordici registrazioni, chiamate run. Le prime due, della durata di un minuto ciascuna, costituiscono la linea di base: al soggetto viene chiesto di rimanere in uno stato di riposo, rispettivamente ad occhi aperti e chiusi. Le dodici run successive, di circa due minuti l'una, sono dedicate ai compiti veri e propri. I compiti richiesti sono quattro, ciascuno eseguito tre volte nel corso della sessione. Ogni compito consiste nell'esecuzione o nell'immaginazione di un movimento cinestetico in corrispondenza di un determinato segnale luminoso. Nel primo compito la comparsa di un segnale luminoso sul lato sinistro o destro dello schermo segnala di iniziare la chiusura e l'apertura ripetuta del corrispettivo pugno. Nel secondo compito, con la stessa metodologia, viene richiesto

di immaginare tale movimento. Allo stesso modo il terzo e il quarto compito prevedono l'apertura e la chiusura ripetuta di entrambi i pugni o di entrambi i piedi, prima eseguita e poi immaginata, a seconda della posizione del segnale luminoso, in alto o in basso nello schermo. All'interno di ogni run le fasi di compito e quelle di riposo si alternano. Il bersaglio resta visibile per circa quattro secondi, durante i quali il soggetto esegue o immagina il movimento; scompare poi e segue un intervallo di riposo di durata simile. Ogni singola ripetizione prende il nome di trial e costituisce l'unità elementare dell'esperimento. Come precedentemente accennato, il lavoro presentato in questa tesi si concentra sulle run di immaginazione motoria. Internamente sono state eseguite delle prove per verificare la coerenza dei risultati dei soggetti tra run di immaginazione ed esecuzione motoria. L'esito del confronto non ha alcuna rilevanza fisiologica e non è stato dunque riportato formalmente: è sufficiente confermare che le prestazioni medie di ogni soggetto risultano sensibilmente migliori nelle run di esecuzione motoria piuttosto che in quelle di immaginazione motoria. Le due run di linea di base, in particolare la prima eseguita ad occhi aperti, sono invece impiegate per caratterizzare il ritmo cerebrale del soggetto a riposo da cui derivare il predittore.

3.3 Organizzazione dei dati

Le registrazioni sono distribuite secondo lo standard BIDS (Brain Imaging Data Structure), una convenzione che stabilisce come debbano essere nominate e organizzate le cartelle e i file di un esperimento neuroscientifico. Il vantaggio è che il percorso di un dato non deve essere costruito manualmente: è sufficiente descrivere quale registrazione si desidera, indicando soggetto, compito e numero di run, perché la libreria di lettura individui il file corrispondente. Oltre al segnale, ogni file contiene le annotazioni, ossia i marcatori

temporali che indicano che cosa stesse facendo il soggetto in ciascun istante. I marcatori sono di tre tipi: uno identifica gli intervalli di riposo, gli altri due le due classi attive della run. Questi ultimi assumono significati differenti a seconda del compito: nelle run dedicate alla mano indicano il pugno sinistro e quello destro, mentre nelle altre indicano entrambi i pugni ed entrambi i piedi. I dati si articolano quindi su tre livelli. La run è la singola registrazione continua, della durata di circa due minuti. Il trial è una singola ripetizione del compito e dura circa quattro secondi. La finestra, infine, è il breve segmento di segnale sul quale il sistema formula una decisione, ricavato suddividendo la registrazione in tratti parzialmente sovrapposti. La distinzione fra trial e finestra è essenziale per una valutazione corretta delle prestazioni e verrà ripresa nel capitolo dedicato all'architettura proposta. Ogni run contiene trenta annotazioni alternate fra riposo e compito, per un totale di circa quindici ripetizioni suddivise fra i due stati. Distinguendo inoltre un compito dall'altro (sopra/sotto o destra/sinistra), si ricavano circa sette trial per classe di attivazione.

3.4 Limiti del dataset

La quantità di dati disponibile per ciascun soggetto rappresenta la limitazione principale. Poco più di venti ripetizioni per classe costituiscono una base ridotta sulla quale addestrare e validare un classificatore, e impongono l'adozione di metodi in grado di operare in un regime di poche osservazioni e molte dimensioni. Il secondo limite riguarda la struttura della sessione. Tutte le registrazioni di un soggetto sono state raccolte in un'unica occasione e senza alcun riscontro immediato: durante l'esperimento il soggetto non osserva mai l'effetto della propria attività cerebrale e non ha quindi modo di correggere la propria strategia. Ne derivano due conseguenze. La prima è l'impossibilità di studiare l'evoluzione della prestazione nel tempo e la trasferibilità di un modello da una sessione all'altra, che

costituisce uno dei problemi pratici più rilevanti per le interfacce cervello-calcolatore. La seconda, più delicata, è che non è possibile distinguere un soggetto realmente incapace di generare un segnale utilizzabile da un soggetto semplicemente non addestrato: in questo dataset le due condizioni sono indistinguibili per costruzione. Vi sono infine alcune irregolarità di minore entità. Tre soggetti sono stati registrati a 128 Hz anziché a 160 Hz, circostanza che non impedisce l'elaborazione ma rende leggermente più rumorose le grandezze stimate su ciascuna finestra; un ulteriore soggetto presenta un numero di annotazioni inferiore all'atteso e dispone quindi di un minor numero di ripetizioni. Le anomalie sono state gestite in modo da non dover escludere alcun soggetto dalla sperimentazione.

Capitolo 4

Classificatore e predittore di illiteracy

Complessivamente, nella scelta del percorso da sviluppare sono stati presi in considerazione parametri di diversa natura, provenienti sia dallo stato dell'arte sia dalla struttura peculiare del dataset. Per raggiungere gli obiettivi proposti è stato necessario dividere il progetto in due parti concettualmente separate: la prima fase prevede lo sviluppo e l'ottimizzazione di un classificatore per il motor imagery, atto a decodificare correttamente l'intenzione cerebrale; successivamente, avendo a disposizione dati dettagliati e discriminativi sulle performance dei singoli soggetti, è stato implementato un algoritmo capace di distinguere soggetti più o meno performanti.

4.1 Struttura del classificatore

Per garantire l'affidabilità delle conclusioni sono stati implementati più classificatori, costruiti su uno scheletro comune che ne consente un confronto rapido e corretto. Sono stati

implementati classificatori binari asincroni basati su sliding window. Il dataset contiene tre run per ciascun compito: per ciascun modello due run su tre sono state utilizzate per la fase di training, mentre la terza per la fase di test. Applicando la metodologia LORO ciascuna run viene utilizzata, a giro, come run di test. Tutti i classificatori sono stati addestrati ad eseguire la classificazione binaria rest/active (distinzione dello stato di riposo da quello di attivazione) oppure T1/T2 (utilizzando la nomenclatura del dataset, distinzione tra due stati di attivazione). Solo per il modello più accurato è stata implementata una pipeline completa a cascata.

4.2 Lettura dei dati e pre-processing

L'intera elaborazione del segnale è stata realizzata in Python attraverso la libreria MNE, che costituisce lo strumento di riferimento per l'analisi di dati elettrofisiologici in questo linguaggio, affiancata dall'estensione MNE-BIDS per la gestione delle raccolte organizzate secondo lo standard descritto nel capitolo precedente. La lettura di una registrazione non richiede la costruzione manuale del percorso del file: è sufficiente dichiarare quale dato si desidera, indicando il soggetto, il compito e il numero della run.

```
bids_path = BIDSPath(subject=subject, task="motion", run=run,
                      datatype="eeg", root=root)

raw = read_raw_bids(bids_path, verbose=False)
events, event_id = mne.events_from_annotations(raw, verbose=False)
raw.load_data(verbose=False)
```

L'oggetto restituito, chiamato Raw, contiene la matrice dei segnali, con una riga per elettrodo e una colonna per istante campionato, insieme a tutte le informazioni descrittive della registrazione, fra cui i nomi e le posizioni degli elettrodi e la frequenza di campionamento. Quest'ultima viene letta dal file e non fissata nel codice: è questa la ragione per cui

i tre soggetti acquisiti a 128 Hz sono stati elaborati senza alcun adattamento, dal momento che tutte le durate sono espresse in secondi e convertite in numero di campioni soltanto al momento dell'uso. La chiamata a `events_from_annotations` traduce i marcatori temporali in una tabella nella quale ogni riga riporta l'istante di inizio di un evento e il codice che lo identifica, mentre il dizionario restituito insieme ad essa associa ciascun codice al nome leggibile dell'annotazione. Per permettere le successive operazioni, `load_data` carica effettivamente i dati in memoria.

Il pre-processing vero e proprio consiste in due sole operazioni.

```
raw.filter(l_freq=L_FREQ, h_freq=H_FREQ, verbose=False)
raw.set_eeg_reference('average', projection=False, verbose=False)
```

La prima è un filtro passa banda. Le componenti al di sotto dell'estremo inferiore corrispondono a derive lente, dovute alla variazione dell'impedenza degli elettrodi, ai movimenti del capo e alla deriva dell'amplificatore, e presentano un'ampiezza molto superiore a quella del segnale di interesse; al di sopra dell'estremo superiore si collocano invece l'attività muscolare e il disturbo introdotto dalla rete elettrica. L'intervallo conservato dipende dal modello: per i classificatori basati sul Common Spatial Patterns è 8-30 Hz, che comprende i ritmi mu e beta, mentre per quelli a banco di filtri è 4-40 Hz. È opportuno osservare che il filtro applicato è a fase zero e utilizza quindi, per calcolare il valore filtrato in un dato istante, anche i campioni successivi a quell'istante. La scelta è legittima in un'analisi condotta a posteriori, quale è quella qui presentata, ma costituisce un vincolo del quale occorrerebbe tenere conto qualora la pipeline venisse trasferita su un sistema funzionante in tempo reale, nel quale i campioni successivi non sono ancora disponibili.

La seconda operazione è l'adozione del riferimento medio. Durante l'acquisizione tutti gli elettrodi sono misurati rispetto a un unico riferimento fisico che non è elettricamente

neutro: qualunque disturbo presente in quel punto si ritrova, con segno opposto, in tutti i canali. Sottraendo a ogni elettrodo la media istantanea di tutti gli altri si elimina la componente comune e si ottiene, per ciascun canale, la misura di quanto esso si discosti dal comportamento medio dello scalpo. La scelta è particolarmente appropriata in questo contesto, nel quale l'informazione ricercata è proprio un'asimmetria fra i due emisferi e rappresenta difatti uno standard frequentemente utilizzato.

Una terza operazione, la rimozione degli artefatti mediante analisi delle componenti indipendenti (ICA), era inizialmente presente in tutte le pipeline ed è stata eliminata a seguito di una verifica sperimentale. Nella banda 8-30 Hz la procedura scartava in media mezza componente su quindici, risultando di fatto inattiva; nella banda più ampia ne scartava un numero considerevole, ma l'accuratezza sui dati di test peggiorava. La ragione risiede nel fatto che il dataset non dispone di canali dedicati alla registrazione dell'attività oculare, per cui l'algoritmo di individuazione automatica è costretto a impiegare come sostituti due elettrodi frontali, finendo per rimuovere anche componenti che contengono segnale utile.

4.3 Segmentazione dei dati

Nelle varie pipeline viene proposto un approccio asincrono basato sulla segmentazione del segnale in finestre scorrevoli (sliding windows). L'obiettivo della ricerca è stato quello di ricavare un algoritmo applicabile in contesti reali e online e comprendere le prestazioni di soggetti senza addestramento a cui, ipoteticamente, viene fornito un dispositivo BCI. La metodologia comunemente usata in tale contesto è quella delle sliding windows che consiste nel suddividere il segnale continuo in brevi segmenti temporali sovrapposti o consecutivi. Attraverso il richiamo del metodo `create_sliding_windows` viene assegnato a `windows`

l'array costituito da circa 246 finestre, ciascuna con 64 canali e 320 campioni. Il richiamo a `create_window_labels` crea l'array `y` contenente le etichette associate alle 246 finestre.

```

windows, window_samples, step_samples, total_samples =
    create_sliding_windows(
        raw, window_size, step_size
    )
windows = windows[:, picks, :]

y, groups = create_window_labels(
    events, event_map, total_samples, window_samples, step_samples,
    threshold=label_threshold, return_groups=True
)

```

La finestra e il passo misurano rispettivamente due secondi e mezzo secondo, che alla frequenza di campionamento di 160 Hz corrispondono a 320 e 80 campioni: due finestre consecutive condividono dunque i tre quarti dei propri campioni. La durata di due secondi rappresenta un compromesso fra due esigenze opposte: una finestra più breve non consentirebbe una stima stabile delle potenze di banda, mentre una più lunga accrescerebbe la latenza del sistema.

Completato il pre-processing, l'analisi viene ristretta agli elettrodi di interesse, individuati per nome all'interno dell'elenco dei canali della registrazione.

```

CHANNELS = ["C3", "C4", "Cz", "Fc3", "Fc4", "Fcz", "Cp3", "Cp4", "Cpz"]
picks = mne.pick_channels(raw.ch_names, CHANNELS)

```

Gli elettrodi conservati sono i nove che sovrastano la corteccia motoria. La chiamata non modifica il segnale ma restituisce soltanto gli indici corrispondenti a quei nomi, che verranno applicati all'array delle finestre nel modo descritto nella sezione seguente.

L'assegnazione delle etichette avviene in due fasi. Prima ogni campione della registrazione riceve l'etichetta dell'evento che lo contiene; successivamente a ciascuna finestra viene attribuita la classe che ne occupa almeno una frazione prefissata dei campioni, indicata dal

parametro `threshold` e fissata a 0,8. Il parametro governa il trattamento delle finestre a cavallo fra un trial e il riposo che lo segue: essendo la finestra lunga due secondi e il trial poco più di quattro, una parte delle finestre contiene necessariamente sia attivazione sia riposo. Attribuire a tali finestre la classe attiva significherebbe insegnare al classificatore a riconoscere come movimento immaginato un segmento costituito per metà da riposo. Questa selezione riduce il numero di finestre utili a 84, equamente ripartite fra le due classi e ricavate da quattordici trial nella misura di sei finestre ciascuno.

Il secondo array restituito, `groups`, riporta per ciascuna finestra l'indice del trial dal quale essa proviene. Questa suddivisione è necessaria per evitare sovrastime nella fase di k-fold cross validation: le finestre estratte dal medesimo trial condividono fino a tre quarti dei propri campioni e sono pertanto quasi identiche fra loro; qualora la cross validation interna alla ricerca degli iperparametri le suddividesse in maniera casuale, alcune di esse comparirebbero simultaneamente nell'insieme di addestramento e in quello di validazione, e il punteggio che determina gli iperparametri risulterebbe sistematicamente sovrastimato. Fornendo i gruppi alla procedura `StratifiedGroupKFold` si impone invece che tutte le finestre di uno stesso trial rimangano dalla medesima parte della suddivisione. Poiché gli indici sono numerati a partire da zero all'interno di ciascuna run, ad essi viene sommato uno scostamento crescente che li rende univoci nell'ambito dell'intero soggetto.

4.4 Estrazione delle feature

Nel corso del lavoro sono stati implementati tre distinti metodi di estrazione delle feature: il Common Spatial Patterns, la sua estensione a banco di filtri e un approccio fondato sulla geometria riemanniana delle matrici di covarianza. Il confronto sistematico fra i tre è stato effettuato su una piccola porzione a causa dell'elevato carico computazionale

e di conseguenza non è stato riportato formalmente nel capitolo dedicato ai risultati; in ogni caso, tale confronto ha evidenziato che il terzo approccio risulta migliore per il dataset utilizzato, sia sul piano delle prestazioni che su quello del costo computazionale; per questa ragione la trattazione che segue è dedicata esclusivamente ad esso.

Sia $X \in \mathbb{R}^{C \times T}$ la matrice associata a una finestra, con $C = 9$ canali e $T = 320$ campioni, filtrata in una determinata sotto-banda e a media nulla. La grandezza sulla quale si fonda l'intero metodo è la matrice di covarianza

$$\Sigma = \frac{1}{T-1} X X^\top.$$

Sulla diagonale sono presenti i valori di potenza di ciascun canale nella banda considerata, ossia la grandezza che la desincronizzazione legata all'evento fa diminuire; gli elementi fuori dalla diagonale misurano invece quanto due canali varino insieme, e descrivono pertanto la configurazione spaziale della sorgente. La matrice condensa in tal modo, in un unico oggetto, sia l'informazione spettrale sia quella spaziale, e a differenza dei filtri del Common Spatial Patterns non richiede alcun addestramento. Essendo Σ simmetrica per costruzione, i suoi elementi distinti sono $C(C+1)/2 = 45$. La stima viene effettuata mediante lo stimatore a contrazione OAS, che tempera la matrice campionaria verso una forma più semplice in misura determinata automaticamente dai dati, così da contenere la variabilità della stima su finestre brevi.

Per evitare contaminazioni tra bande distinte, si adotta un banco di filtri costituito dalle tre sotto-bande $\mathcal{B} = \{(8, 13), (13, 20), (20, 30)\}$ Hz, calcolando una matrice di covarianza per ciascuna di esse; il numero complessivo di feature per finestra ammonta quindi a $3 \times 45 = 135$.

Le matrici di covarianza non costituiscono un ordinario spazio vettoriale. Esse ap-

partengono infatti all'insieme $\mathcal{P}_C$ delle matrici simmetriche definite positive: la media aritmetica di due matrici di covarianza, pur essendo calcolabile, non rappresenta il punto ad esse intermedio sulla varietà e descrive un segnale sistematicamente più energetico di entrambe. La metrica appropriata è quella affine-invariante, secondo la quale la distanza fra due matrici è

$$\delta(\Sigma_1, \Sigma_2) = \left\| \log\left(\Sigma_1^{-1/2} \Sigma_2 \Sigma_1^{-1/2}\right) \right\|_F,$$

e il baricentro di un insieme di N matrici è definito come il punto che minimizza la somma dei quadrati di tali distanze,

$$\bar{\Sigma} = \arg \min_{\Sigma \in \mathcal{P}_C} \sum_{n=1}^N \delta^2(\Sigma, \Sigma_n).$$

Su questa nozione si fonda l'operazione che caratterizza il metodo. Fra una run e l'altra variano le impedenze degli elettrodi, il grado di vigilanza del soggetto e il livello complessivo di attivazione, con la conseguenza che le covarianze di run differenti occupano regioni differenti della varietà e un classificatore addestrato su due run ritrova la terza traslata. Il rimedio consiste nel riportare ciascuna run sul proprio baricentro mediante la trasformazione di congruenza

$$\tilde{\Sigma}_n = \bar{\Sigma}^{-1/2} \Sigma_n \bar{\Sigma}^{-1/2},$$

la quale conduce il baricentro esattamente nella matrice identità e vi trasporta con sé l'intera nuvola. L'efficacia del procedimento discende da una proprietà della metrica adottata: la congruenza ne è un'isometria, giacché la distanza $\delta(W\Sigma_1 W, W\Sigma_2 W) = \delta(\Sigma_1, \Sigma_2)$ per ogni W invertibile. Il riallineamento costituisce dunque un movimento rigido, che modifica la posizione della nuvola senza alterarne la forma interna: lo scostamento comune

all'intera run viene eliminato, mentre la differenza fra le classi, essendo interna alla run, sopravvive immutata. Le misure condotte sul soggetto 001 confermano quanto descritto: i baricentri delle tre run distano fra loro da 0,41 a 0,62, valore confrontabile con la distanza fra i centri delle due classi, compresa fra 0,81 e 1,07; dopo il riallineamento la prima si annulla mentre la seconda rimane identica.

È opportuno sottolineare che il baricentro viene stimato senza fare uso delle etichette, ragione per la quale può essere calcolato anche sulla run di test senza che ciò configuri una forma di leakage: l'operazione rientra nella categoria dell'adattamento di dominio non supervisionato e corrisponde, in un sistema reale, alla registrazione di un breve segnale di calibrazione precedente all'utilizzo. È stata comunque implementata anche una variante più conservativa, nella quale il riferimento viene stimato sulle sole run di addestramento.

Poiché i classificatori lineari operano in spazi piatti, l'ultimo passaggio consiste nel proiettare le covarianze riallineate nello spazio tangente alla varietà. Il punto di tangenza è la matrice identità, scelta non arbitraria ma conseguenza del riallineamento, che vi ha condotto il baricentro di ogni run: la proiezione risulta pertanto accurata nell'intorno in cui i dati si addensano ed è la medesima per tutte le run, condizione necessaria affinché le coordinate siano confrontabili. Il vettore di feature associato alla finestra n si ottiene applicando il logaritmo matriciale e riordinando in un vettore gli elementi della porzione triangolare superiore,

$$s_n = \text{vec}\left(\log \tilde{\Sigma}_n\right),$$

dove gli elementi esterni alla diagonale vengono moltiplicati per $\sqrt{2}$ affinché la norma euclidea del vettore coincida con quella di Frobenius della matrice. Concatenando i vettori relativi alle tre sotto-bande si ottengono le 135 componenti sulle quali opera il classificatore.

4.5 Classificazione e validazione

La scelta del classificatore è stata dettata dalle proporzioni del problema. Ogni fold dispone di circa centosessanta finestre di addestramento, provenienti però da appena ventotto trial indipendenti, a fronte di 135 feature: un regime nel quale la quantità di parametri liberi da stimare è confrontabile con quella dei dati disponibili. È stata pertanto adottata l'analisi discriminante lineare con contrazione, la quale, anziché ricorrere a una regolarizzazione da calibrare per tentativi, tempera la matrice di covarianza stimata verso una forma semplice secondo la relazione

$$\hat{\Sigma}_\gamma = (1 - \gamma) \hat{\Sigma} + \gamma \frac{\text{tr}(\hat{\Sigma})}{d} I,$$

nella quale il coefficiente γ può essere determinato analiticamente dai dati stessi.

```
pipe = Pipeline([
    ("scaler", StandardScaler()),
    ("clf", LinearDiscriminantAnalysis(solver="lsqr")),
])

cv = StratifiedGroupKFold(n_splits=5, shuffle=True, random_state=42)
grid = GridSearchCV(pipe, param_grid, cv=cv,
                    scoring="balanced_accuracy", n_jobs=-1)
grid.fit(X_train, y_train, groups=groups_train)
```

La standardizzazione che precede il classificatore riconduce ciascuna delle 135 componenti a media nulla e varianza unitaria, impedendo che le sotto-bande più energetiche dominino quelle più deboli per la sola ragione della loro scala. La griglia degli iperparametri è volutamente minima e comprende il solo coefficiente di contrazione: esplorare decine di combinazioni disponendo di ventotto trial indipendenti significherebbe selezionare il rumore anziché il segnale. La cross validation interna impiega la suddivisione per gruppi descritta nella sezione precedente, così che il punteggio sulla cui base l'iperparametro viene

scelto risulti onesto e non gonfiato dalla sovrapposizione fra finestre.

La validazione esterna adotta il criterio Leave-One-Run-Out già illustrato: il modello viene addestrato su due run e valutato sulla terza. La scelta è più severa di quella, assai diffusa in letteratura, che suddivide casualmente i trial di tutte le run: quest'ultima colloca nell'insieme di valutazione segmenti provenienti dalle medesime registrazioni impiegate per l'addestramento, e misura pertanto la separabilità all'interno di una sessione anziché la capacità di generalizzare a una sessione nuova, che è invece la condizione in cui un sistema reale si trova a operare. La metrica adottata è la balanced accuracy, ossia la media delle accuratèzze ottenute su ciascuna classe: questo ultimo passaggio è necessario dato che all'interno della sessione non è garantito un uguale numero di finestre per ciascuna classe.

```
probs = grid.predict_proba(X_test)
max_probs = np.max(probs, axis=1)
predictions = np.argmax(probs, axis=1)

threshold = START_THRESHOLD
accepted_mask = max_probs >= threshold
while np.sum(accepted_mask) < MIN_ACCEPTED_RATIO * len(y_test) and
    threshold > MIN_THRESHOLD:
    threshold -= 0.05
    accepted_mask = max_probs >= threshold
```

L'ultima fase introduce quella che costituisce una precisa scelta di progetto. Il classificatore non emette la classe più probabile in ogni circostanza, ma soltanto quando la probabilità ad essa associata supera una soglia: al di sotto di tale valore la finestra viene scartata e nessun comando viene prodotto. La motivazione è di natura applicativa, giacché in un'interfaccia cervello-calcolatore il mancato invio di un comando rappresenta un inconveniente assai minore rispetto all'invio di un comando errato. La soglia parte dal valore 0,90 e viene abbassata a passi di 0,05 finché non risulti accettato almeno il settanta per cento delle finestre.

Se ne deduce che l'accuratezza non è mai una grandezza assoluta, bensì sempre relativa a una determinata percentuale di campioni scartati, e le due quantità vanno riportate congiuntamente. Un'accuratezza elevata ottenuta rifiutando la metà delle finestre non è confrontabile con un'accuratezza inferiore ottenuta rifiutandone un quarto.

Infine, è stata realizzata una pipeline completa a due stadi, nella quale il primo determina se il soggetto stia immaginando un movimento e il secondo, interrogato soltanto in caso affermativo, ne stabilisce la natura fra i quattro possibili compiti. Le due probabilità vengono composte in un'unica distribuzione sui cinque esiti finali, alla quale si applica la medesima soglia descritta poc'anzi: qualora nessuno dei due stadi risulti sufficientemente sicuro, la confidenza complessiva si abbassa e la finestra viene scartata, anziché dare luogo a un errore non più recuperabile ai livelli successivi.

4.6 Il predittore di illiteracy

L'osservazione dei risultati provenienti da metodi di natura diversa evidenzia un aspetto cruciale: la variabilità fra i soggetti è di gran lunga superiore alla variabilità fra i metodi. Se dunque la prestazione dipende in misura preponderante dalla persona, diviene legittimo domandarsi se sia possibile prevederla prima ancora di somministrare l'addestramento, individuando in anticipo i soggetti per i quali il paradigma di immaginazione motoria non produrrà un segnale utilizzabile.

Il fondamento neurofisiologico dell'ipotesi è il meccanismo stesso sul quale l'intero sistema si poggia. L'immaginazione motoria viene riconosciuta in quanto desincronizza il ritmo mu sensomotorio, riducendone la potenza; l'ipotesi è dunque che, in un soggetto con un ritmo mu poco marcato in stato di riposo, sia difficile riconoscere eventuali desincronizzazioni. La misura viene condotta sulla prima run del protocollo, un minuto di registrazione

a riposo con gli occhi aperti, la quale non è impiegata da alcuno dei classificatori: i due insiemi di dati non si intersecano e non sussiste pertanto alcuna circolarità fra ciò che viene previsto e ciò che viene misurato.

```
def laplacian_signal(raw, centre):  
    neighbours = LAPLACIAN_NEIGHBOURS[centre]  
    centre_data = raw.get_data(picks=[centre])[0]  
    ring_data = raw.get_data(picks=neighbours).mean(axis=0)  
    return centre_data - ring_data
```

Il segnale viene dapprima sottoposto a un laplaciano di superficie, ottenuto sottraendo a ciascun elettrodo centrale la media dei quattro che lo circondano. L'operazione è indispensabile per la validità della misura: il ritmo mu è un fenomeno focale, circoscritto alla corteccia sensomotoria, mentre il ritmo alfa occipitale, che occupa il medesimo intervallo di frequenze, è diffuso e per conduzione di volume raggiunge anche gli elettrodi centrali. In assenza del laplaciano un soggetto dotato di alfa posteriore pronunciata apparirebbe dotato di un mu altrettanto pronunciato, e il predittore misurerebbe una grandezza priva di relazione con il compito.

Dello spettro di potenza, stimato con il metodo di Welch su segmenti di due secondi, non interessa la potenza assoluta nella banda, la quale dipende in larga parte da fattori estranei all'attività cerebrale quali lo spessore del cranio e l'impedenza degli elettrodi. Interessa invece quanto il ritmo emerga rispetto all'attività di fondo. Poiché in scala doppiamente logaritmica il fondo elettroencefalografico è approssimabile con una retta, se ne stimano i coefficienti mediante regressione lineare sull'intervallo 3-40 Hz, escludendo dalla stima la banda mu affinché il picco non concorra a innalzare il fondo rispetto al quale viene poi misurato. Il predittore è quindi definito come

$$p = 10 \log_{10} \max_{f \in \mu} \frac{P(f)}{P_{\text{fondo}}(f)},$$

ossia la massima elevazione del picco sopra il fondo all'interno della banda, espressa in decibel, alla quale si accompagna la frequenza in cui tale massimo si verifica, corrispondente al ritmo μ individuale del soggetto.

La misura viene condotta separatamente su C3 e C4 e di essa si conservano la media e il minimo fra i due emisferi. La distinzione non è superflua: un soggetto può presentare un ritmo μ marcato da un lato e pressoché assente dall'altro, e poiché la classificazione fra mano sinistra e destra si fonda sul confronto fra i due emisferi, il valore minimo descrive la situazione in modo più fedele di quanto non faccia la media.

Il confronto fra il predittore e la prestazione effettivamente conseguita dai soggetti, unitamente alla regola di selezione che se ne può derivare, è riportato nel capitolo successivo. Si osservi infine che l'impiego dell'attività a riposo per la previsione della prestazione è stato già proposto in letteratura sul medesimo dataset [9]; rispetto a tali lavori la misura qui adottata differisce per l'adozione del laplaciano, che isola il ritmo sensomotorio da quello occipitale, e per la scelta di quantificare l'emergenza del picco rispetto al fondo anziché la potenza relativa della banda.

Capitolo 5

Risultati sperimentali

Tutti i risultati riportati in questo capitolo sono stati ottenuti sui 109 soggetti del dataset, con la validazione Leave-One-Run-Out descritta nel capitolo precedente e con l'estrazione di feature riemanniana a banco di filtri.

Prima di leggere qualunque cifra occorre fissare due riferimenti. Il primo è il livello del caso, che per una classificazione binaria vale il cinquanta per cento. Il secondo, meno ovvio ma più importante, è la soglia di significatività: disponendo di circa quarantadue trial indipendenti per soggetto, un classificatore privo di qualunque informazione supera il cinquanta per cento piuttosto spesso per effetto del solo caso, e il valore oltre il quale si può escludere questa eventualità con una confidenza del novantacinque per cento è pari al 62,7 per cento. Un soggetto che ottenga il cinquantotto per cento non è un soggetto che funziona male: è un soggetto per il quale non è possibile affermare che abbia prodotto alcun segnale utilizzabile.

5.1 Le classificazioni binarie

Sono state condotte tre distinte classificazioni binarie, tutte sulle run di immaginazione motoria. La prima distingue lo stato di riposo da quello di attivazione, senza interrogarsi su quale movimento venga immaginato; la seconda distingue i pugni dai piedi; la terza il pugno sinistro dal destro.

compito	accuratezza	mediana	dev. std.	scarti	sopra 62,7%
riposo / attivazione	73,61%	73,01%	10,60	25,8%	90/109
pugni / piedi	69,98%	71,67%	16,02	19,1%	69/109
sinistra / destra	62,55%	59,03%	14,69	22,1%	48/109

Tabella 5.1: Prestazione media sui 109 soggetti nelle tre classificazioni binarie. L'accuratezza è la balanced accuracy calcolata sulle sole finestre accettate, e va letta congiuntamente alla percentuale di finestre scartate riportata nella penultima colonna.




Figura 5.1: Distribuzione della prestazione individuale nei tre compiti. La linea punteggiata indica il livello del caso, quella tratteggiata la soglia di significatività.

L'ordinamento dei tre compiti corrisponde a quanto ci si attende sul piano neurofisiologico. Riconoscere se il soggetto stia immaginando qualcosa è il compito più semplice, perché la desincronizzazione interessa entrambi gli emisferi e il contrasto da rilevare è una differenza di livello complessivo. Più difficile è la classificazione dei pugni rispetto ai piedi, poiché le due aree corticali coinvolte, laterale l'una e mediale l'altra, sono ben separate nel-

lo spazio. Distinguere la mano sinistra dalla destra, infine, è il compito più arduo, perché le due aree sono simmetriche e vicine e il contrasto è una sottile asimmetria fra emisferi.

La figura 5.1 mostra però che la media riassume assai poco. In tutti e tre i compiti la distribuzione è ampia e attraversa la soglia di significatività: nel caso sinistra contro destra la deviazione standard è di quasi quindici punti e i soggetti vanno dal 29,97 al 97,07 per cento. Soltanto 48 soggetti su 109, ossia il 44 per cento, superano la soglia di significatività nella classificazione sinistra contro destra; sono 69 per pugni contro piedi e 90 per riposo contro attivazione.

5.1.1 Il ruolo dei campioni scartati

La colonna degli scarti della tabella 5.1 indica un parametro fondamentale per la corretta lettura dei risultati dei modelli riportati.

Utilizzando un approccio probabilistico, tramite il richiamo del metodo `grid.predict_proba(X_test)` si è sviluppato un meccanismo di selezione delle finestre che fa sopravvivere solo quelle a cui il modello associa una maggiore certezza: ogni classificazione del modello viene scartata se il grado di certezza ad essa associata non supera una determinata soglia.

Il numero di finestre (o, ugualmente, di classificazioni) scartate varia da soggetto a soggetto attraverso i tre parametri `START_THRESHOLD(0.90)`, `MIN_THRESHOLD(0.50)` e `MIN_ACCEPTED_RATIO(0.70)`: la soglia iniziale è pari a 0,90 e a questa il modello sottrae una quantità fissa pari a 0,05 fino a che non viene accettato almeno il 70% delle classificazioni o fino al raggiungimento della soglia minima.

Ne consegue che la lettura dell'accuratezza debba essere effettuata congiuntamente al relativo valore di finestre scartate. È possibile apprezzare tale fattore nei risultati della tabella 5.1: la differenza di accuratezza media tra i compiti della prima e della seconda

riga, pari a circa il 4%, è sensibilmente assottigliata dalla differenza della percentuale delle finestre scartate, pari a 6,7%.

L'impiego di questa metodologia è derivato da osservazioni di natura tecnica: in un sistema BCI reale e online l'omissione di un comando costituisce un disagio modesto, mentre l'accettazione di una classificazione errata risulta più fastidiosa per l'utente finale.

5.1.2 Il confronto con e senza scarto

Per quantificare il contributo della soglia probabilistica, la classificazione pugni contro piedi è stata ripetuta con la medesima pipeline ma con soglia nulla, accettando dunque tutte le finestre. A livello di popolazione il guadagno appare modesto: l'accuratezza media passa dal 67,53 al 69,98 per cento, ossia **meno di due punti e mezzo** a fronte del 19,1 per cento di finestre scartate.

La media, tuttavia, mescola soggetti per i quali lo scarto ha effetti molto diversi. Nella tabella 5.2 i soggetti sono suddivisi in quartili secondo l'accuratezza ottenuta senza scarto, così che il raggruppamento non dipenda dalla grandezza che si vuole confrontare.

quartile	senza scarto	con scarto	guadagno	scarti
primo (78–98%)	87,04%	89,43%	+2,40	8,4%
secondo (68–78%)	73,40%	77,90%	+4,51	20,1%
terzo (56–68%)	61,57%	64,24%	+2,67	23,6%
quarto (38–55%)	48,81%	49,13%	+0,32	24,1%

Tabella 5.2: Classificazione pugni/piedi con e senza scarto delle finestre, per quartili di soggetti ordinati secondo l'accuratezza senza scarto.

Il quadro che ne emerge è diverso da quello suggerito dalla media. Per i soggetti del primo quartile lo scarto riduce l'errore dal 13,0 al 10,5 per cento, quasi un quinto degli errori in meno, rinunciando però soltanto a l'8,4 per cento delle finestre; per i dieci soggetti

migliori gli scarti scendono al 3,9 per cento. All'estremo opposto, nel quarto quartile viene scartata una finestra su quattro senza alcun beneficio apprezzabile: quando il classificatore non dispone di informazione utile, anche le sue predizioni più sicure sono casuali, e la soglia si limita a ridurre il numero di comandi emessi.

Il basso guadagno medio non indica dunque che la soglia sia inefficace, bensì che la gran parte degli scarti si concentra sui soggetti per i quali non vi è nulla da recuperare. Per i soggetti che producono un segnale utilizzabile, lo scarto rimuove proprio le finestre ambigue a un costo contenuto, confermando ancora una volta che l'effetto di una scelta di progetto dipende in primo luogo dalla persona.

5.2 La coerenza della prestazione fra compiti

Il dato più rilevante del paragrafo precedente non è la prestazione media del metodo, bensì l'ampiezza della dispersione fra soggetti. Si pone allora la domanda se tale dispersione rifletta una proprietà stabile della persona oppure sia il risultato di fluttuazioni casuali.




Figura 5.2: Prestazione dei medesimi soggetti in coppie di compiti differenti. Ogni punto rappresenta un soggetto.

La risposta, riportata in figura 5.2, è netta. Le prestazioni dei medesimi soggetti in compiti diversi sono correlate in misura considerevole: il coefficiente di Spearman vale 0,564

fra sinistra/destra e pugni/piedi, 0,516 fra pugni/piedi e riposo/attivazione e 0,308 fra sinistra/destra e riposo/attivazione. Un soggetto che riesce in un compito tende a riuscire anche negli altri, che sono classificazioni distinte, addestrate separatamente e condotte su registrazioni differenti.

La conclusione è che la variabilità osservata non è rumore ma **descrive la persona**: l'impiego di metodi differenti (di cui, si ricorda, è stato riportato esclusivamente l'ultimo modello) e le classificazioni binarie di diversa natura confermano la validità delle singole strategie ed evidenziano la possibilità di estrarre dati utili anche con un ridotto numero di campioni.

5.3 Il sistema completo a cascata

I risultati finora mostrati sono stati sufficientemente incoraggianti per sviluppare un **sistema completo a cascata**, caratterizzato da due stadi distinti di classificazione. Il primo stadio stabilisce se la finestra corrente appartiene alla classe di attivazione oppure no e, in caso di esito positivo, delega al secondo stadio la scelta della precisa classe di attivazione. Il sistema a due stadi è stato valutato sull'unione di due run tenute fuori contemporaneamente, una per ciascuna famiglia di compiti, così da disporre nell'insieme di test di tutte e cinque le classi finali: riposo, pugno sinistro, pugno destro, entrambi i pugni ed entrambi i piedi. Il livello del caso è dunque il venti per cento.

Il primo stadio raggiunge il 68,18 per cento e il secondo il 38,13 per cento su quattro classi, quest'ultimo valutato sulle finestre effettivamente attive, ossia supponendo che il primo stadio non commetta errori. La catena completa consegue il 36,46 per cento con il 26,3 per cento di campioni scartati.

Il confronto che questa architettura consente di effettuare è quello fra la catena e il




Figura 5.3: A sinistra le prestazioni dei due stadi valutati separatamente, il loro prodotto e la catena effettiva; in rosso il livello del caso di ciascuno. A destra la matrice di confusione della catena, normalizzata per riga.

prodotto dei suoi stadi. Se gli errori dei due livelli si accumulassero senza alcuna compensazione, ci si attenderebbe un valore prossimo al 25,99 per cento; la catena ne consegue invece 36,46, vale a dire **dieci punti in più**. Il merito è della composizione morbida delle probabilità: uno stadio sicuro compensa un secondo stadio tiepido, e soprattutto i casi nei quali nessuno dei due risulta convinto vengono scartati anziché trasformarsi in errori. Il difetto classico delle architetture in cascata, per cui un errore commesso al primo livello non è più recuperabile, viene in tal modo largamente attenuato.

La matrice di confusione di figura 5.3 indica però con chiarezza dove il sistema perda. La classe di riposo viene riconosciuta nel settantotto per cento dei casi, mentre ciascuna classe di movimento viene ricondotta al riposo in una percentuale compresa fra il venticinque e il trentacinque per cento. Il collo di bottiglia non è dunque la discriminazione fra i quattro movimenti bensì la sensibilità del primo stadio, che lascia sfuggire una quota consistente delle attivazioni: un movimento non rilevato al primo livello è definitivamente perduto.

5.4 Le prestazioni migliori

Le medie riportate finora descrivono la popolazione nel suo insieme, ma dicono poco su quanto l'algoritmo sia in grado di ottenere quando il soggetto produce un segnale utilizzabile. Per rispondere a questa domanda la tabella 5.3 riporta, per ciascun compito, il soggetto migliore e la media del dieci per cento migliore della popolazione, ossia gli undici soggetti con l'accuratezza più elevata. Il secondo dato è il più significativo, perché meno esposto alla fortuna di un singolo soggetto.

compito	soggetto migliore		10% migliore		sopra 90%
	accuratezza	scarti	accuratezza	scarti	
riposo / attivazione	92,69%	24,5%	90,26%	24,2%	7/109
pugni / piedi	98,80%	0,4%	94,56%	4,2%	11/109
sinistra / destra	97,07%	4,8%	89,05%	11,7%	4/109
cascata (5 classi)	75,54%	28,3%	61,72%	27,2%	0/109

Tabella 5.3: Prestazione del soggetto migliore e media degli undici soggetti migliori per ciascun compito. Per la cascata il livello del caso è il venti per cento.

Il quadro è molto diverso da quello delle medie. Nella classificazione pugni contro piedi gli undici soggetti migliori superano in media il 94 per cento scartando appena il 4 per cento delle finestre, e il migliore sbaglia poco più di una finestra su cento. Anche nel compito sinistra contro destra, il più arduo e quello con la media più bassa, il dieci per cento migliore si attesta intorno all'89 per cento. Nel sistema a cascata, dove il caso vale il venti per cento, il soggetto migliore riconosce correttamente tre finestre su quattro fra cinque classi.

Due osservazioni impediscono di attribuire questi valori al caso. La prima è che si collocano ben oltre la soglia di significatività del 62,7 per cento: il massimo su 109 soggetti è per costruzione un dato ottimistico, ma nessuna fluttuazione casuale su circa quaranta

trial può portare un classificatore privo di informazione oltre il novanta per cento. La seconda è che i soggetti migliori sono sempre gli stessi: i soggetti 029, 042 e 062 compaiono fra i cinque migliori sia nel compito pugni/piedi sia in quello sinistra/destra sia nella cascata, coerentemente con quanto osservato nel paragrafo sulla coerenza fra compiti.

Questi risultati vanno letti alla luce delle condizioni descritte nell'introduzione. I soggetti non avevano ricevuto alcun addestramento all'immaginazione motoria, non hanno mai ricevuto un riscontro della propria attività e ciascun modello binario è stato addestrato su appena due run, circa quattro minuti di registrazione. Ciò nonostante, per una parte della popolazione l'algoritmo raggiunge accuratèzze paragonabili a quelle di un sistema utilizzabile nella pratica. Il risultato conferma che, **quando il soggetto produce un ritmo sensomotorio marcato, la pipeline è già in grado di classificarlo con buona accuratezza anche in assenza di qualunque addestramento**, e che la bassa media della popolazione dipende in larga parte dai soggetti che tale segnale non lo producono.

5.5 Il predittore di illiteracy

Il predittore è stato calcolato su tutti e 109 i soggetti a partire dalla sola run di linea di base, e confrontato con la prestazione conseguita nelle run di compito. Trattandosi di due insiemi di registrazioni disgiunti, fra le due misure non sussiste alcuna forma di circolarità. Anche in questo caso si è fatto uso del coefficiente di Spearman, valutato sulla base del confronto tra il picco dei ritmi μ rispetto al fondo $1/f$ e l'accuratezza del relativo soggetto.

Le quattro configurazioni esaminate producono coefficienti compresi fra 0,36 e 0,44, nonostante si riferiscano a compiti differenti, a insiemi di elettrodi differenti e a due diverse modalità di aggregazione fra emisferi. Un minuto di registrazione a riposo predice la prestazione nella discriminazione fra le due mani press'a poco con la stessa efficacia con

configurazione	ρ media dei canali	ρ minimo fra i canali
sinistra / destra, canali C3 e C4	0,376	0,416
pugni / piedi, canali C3, C4 e Cz	0,443	0,372
sinistra / destra, senza laplaciano	0,360	—

Tabella 5.4: Correlazione di Spearman fra la prominente del ritmo sensomotorio a riposo e la prestazione conseguita, su 109 soggetti. Tutti i valori riportati hanno significatività inferiore a 10^{-3} .




Figura 5.4: Prominenza del ritmo sensomotorio a riposo contro prestazione conseguita: a sinistra per il compito sinistra/destra, a destra per il compito pugni/piedi. Ogni punto è un soggetto.

cui predice quella fra pugni e piedi.

L'osservazione ha una conseguenza interpretativa precisa. Se il predittore misurasse una capacità specifica del compito, per esempio l'attitudine a lateralizzare l'attività fra i due emisferi, ci si attenderebbe una correlazione sensibilmente più elevata con il compito sinistra contro destra rispetto a quello pugni contro piedi. Il fatto che le due siano quasi equivalenti indica che ciò che viene misurato è **una proprietà generale del soggetto**, ossia quanto marcata sia la sua attività ritmica sensomotoria, e non la sua abilità in un compito particolare. Il dato è coerente con quanto osservato nel paragrafo sulla coerenza fra compiti, ed è esattamente ciò che rende il predittore utilizzabile come strumento di selezione preliminare, in quanto indipendente dall'applicazione che si intenda poi realizzare.

Analoga considerazione vale per la terza riga della tabella. Rimuovendo il laplaciano di superficie, e misurando dunque la prominenza sul canale grezzo secondo la prassi adottata in letteratura, il valore assoluto della prominenza si dimezza ma la correlazione con la prestazione rimane sostanzialmente immutata, passando da 0,376 a 0,360. Il filtro spaziale modifica pertanto la grandezza misurata ma non l'ordinamento dei soggetti, e ciò induce a ritenere che il predittore non stia cogliendo il ritmo μ in quanto distinto dall' α occipitale, bensì una caratteristica più generale dell'attività ritmica individuale.

5.5.1 L'impiego come regola di selezione

La correlazione misura l'esistenza di una relazione, non la sua utilità pratica. Per valutare quest'ultima si è verificato come vari l'accuratezza media della popolazione al variare della quota di soggetti esclusi sulla base del predittore.

soglia sul predittore	soggetti esclusi	accuratezza media dei rimanenti
nessuna	0/109	62,55%
10° percentile	11/109	63,39%
20° percentile	22/109	63,64%
30° percentile	33/109	64,16%
40° percentile	44/109	65,44%

Tabella 5.5: Accuratezza media nel compito sinistra/destra al variare della quota di soggetti esclusi in base al predittore.

L'esito, riportato in tabella 5.5, è modesto e va dichiarato come tale: escludendo il quaranta per cento della popolazione l'accuratezza media dei rimanenti cresce di meno di tre punti. Con un coefficiente di correlazione di poco superiore a 0,4, del resto, un simile risultato è quello che ci si deve attendere, giacché il predittore spiega una frazione limitata della variabilità osservata.

Occorre inoltre osservare che una tabella di questa natura tende per costruzione a mo-

strarsi favorevole: escludendo i soggetti peggiori secondo una qualunque grandezza anche debolmente correlata con la prestazione, la media dei rimanenti non può che salire. Una valutazione più severa richiederebbe di trattare il predittore come un test diagnostico, misurandone sensibilità e specificità rispetto alla soglia di significatività, e di confrontarne l'esito con quello di un'esclusione condotta a caso.

5.6 Sintesi

I risultati esposti convergono verso una conclusione unitaria. La differenza fra i metodi di estrazione delle feature si misura in pochi punti percentuali, mentre la differenza fra i soggetti supera i sessanta punti; tale differenza non è casuale, poiché si conserva attraverso compiti e registrazioni distinti; ed è in parte prevedibile a partire da un solo minuto di attività a riposo, sebbene con un margine di errore ampio.

Il fattore limitante di un'interfaccia cervello-calcolatore basata sull'immaginazione motoria, almeno entro i confini di questo dataset, non è dunque l'algoritmo di decodifica bensì la persona che si trova davanti al dispositivo.

Capitolo 6

Conclusione e sviluppi futuri

L'architettura mostrata risponde quindi alle domande poste nel progetto:

- Rafforza quanto già noto nella letteratura scientifica nell'ambito della BCI illiteracy ed evidenzia la necessità di una fase di addestramento
- Propone un miglioramento alle classiche pipeline attraverso il meccanismo di selezione delle finestre
- Sperimenta, per questo preciso dataset, una metodologia ancora inutilizzata e basata sulle onde mu per la costruzione di un predittore

6.1 Setup sperimentale

Ogni sperimentazione effettuata rappresenta una solida base, con le dovute limitazioni, da cui poter derivare modelli con maggiore complessità e precisione.

L'approccio del classificatore basato sulla geometria riemanniana, grazie all'applicazione del riallineamento, si presta ad adattamenti per valutazioni cross-subject o applicazioni

di transfer learning. La presenza di criteri valutativi rigidi come la LORO e il k-folding, affiancati alla metodologia delle sliding window (meno generosa del tipico epoching), fornisce un modello rigido ma con elevata interpretabilità e affidabilità.

La selezione delle finestre attualmente non rappresenta un approccio altamente migliorativo: l'aumento medio dell'accuratezza non compensa adeguatamente il numero di classificazioni scartate. Nonostante ciò è importante sottolineare, come già osservato nel capitolo precedente, la differenza che intercorre tra i soggetti a più alte prestazioni e quelli affetti da illiteracy o che necessitano addestramento. Per la prima categoria, a fronte di un modesto scarto è possibile apprezzare un miglioramento delle performance, seppur ridotto. Il prossimo step potrebbe dunque prevedere lo sviluppo di un algoritmo specializzato che, per ogni soggetto, individua il rapporto ottimale tra scarti e miglioramento. Completato questo passaggio sarà possibile sperimentare l'approccio attraverso un sistema real time: valutando la percezione e i feedback degli utenti e analizzando parametri quali il numero di finestre scartate per ogni compito sarà possibile ottenere, dallo stesso sistema di partenza, un comportamento più generoso per l'utente finale.

Infine, il predittore di illiteracy fornisce già allo stato attuale dei risultati soddisfacenti che mostrano una correlazione tra i ritmi a riposo e le performance relative, ma si limita ad osservare un singolo minuto di run per soggetti non addestrati. Studi più approfonditi potrebbero analizzare l'andamento del picco μ a seguito di una serie di sessioni di addestramento o affiancare altri parametri valutativi e mescolare le valutazioni. Inoltre allo stato attuale, essendo il coefficiente di Spearman non particolarmente elevato, non è stato addestrato nessun modello in grado di distinguere soggetti a basse performance da soggetti ad alte performance.

Ringraziamenti

Tenendo in mano questo documento si può essere portati a pensare sia il frutto di un tirocinio,

Bibliografia

- [1] L M Nirenberg, J Hanley, and E B Stear. A new approach to prosthetic control: EEG motor signal tracking with an adaptively designed phase-locked loop. *IEEE Trans Biomed Eng*, 18(6):389–398, November 1971.
- [2] F Lotte, L Bougrain, A Cichocki, M Clerc, M Congedo, A Rakotomamonjy, and F Yger. A review of classification algorithms for EEG-based brain-computer interfaces: a 10 year update. *Journal of neural engineering*, 15(3):031005, 2018.
- [3] Reza Abiri, Soheil Borhani, Eric W Sellers, Yang Jiang, and Xiaopeng Zhao. A comprehensive review of EEG-based brain-computer interface paradigms. *Journal of neural engineering*, 16(1):011001, 2019.
- [4] Khondoker Murad Hossain, Md Ariful Islam, Shahera Hossain, Anton Nijholt, and Md Atiqur Rahman Ahad. Status of deep learning for EEG-based brain-computer interface applications. *Frontiers in computational neuroscience*, 16:1006763, 2022.
- [5] Janis Peksa and Dmytro Mamchur. State-of-the-art on brain-computer interface technology. *Sensors (Basel, Switzerland)*, 23(13), 2023.
- [6] Hongyu Zhang, Le Jiao, Songxiang Yang, Haopeng Li, Xinzhan Jiang, Jing Feng, Shuhuai Zou, Qiang Xu, Jianheng Gu, Xuefeng Wang, and Baojian Wei. Brain-computer

- interfaces: the innovative key to unlocking neurological conditions. *International journal of surgery (London, England)*, 110(9):5745–5762, 2024.
- [7] Olga Maslova, Yuliya Komarova, Natalia Shusharina, Alexander Kolsanov, Alexander Zakharov, Evgenia Garina, and Vasiliy Pyatin. Non-invasive EEG-based BCI spellers from the beginning to today: a mini-review. *Frontiers in human neuroscience*, 17:1216648, 2023.
- [8] F Lotte, M Congedo, A Lécuyer, F Lamarche, and B Arnaldi. A review of classification algorithms for EEG-based brain-computer interfaces. *Journal of neural engineering*, 4(2):R1–R13, 2007.
- [9] Kun Wang, Feifan Tian, Minpeng Xu, Shanshan Zhang, Lichao Xu, and Dong Ming. Resting-state EEG in alpha rhythm may be indicative of the performance of motor imagery-based brain-computer interface. *Entropy (Basel)*, 24(11):1556, October 2022.